

作业4B：中频短线量化全流程

因子挖掘 → IC/共线质检 → LGBM赋权 → 1~2日持仓样本外回测

15.37%

样本外累计收益

-40.59%

最大回撤

学生：丁致宇 学号：202331060205

课程：金融与经济数据挖掘 日期：2026年6月

审查结论：旧版本存在口径偏差，已重算修正

本版严格按作业4B要求复现四因子流程，样本外区间只用于回测。

发现的问题

1. 原结果混入4个扩展因子
2. IC/OLS覆盖了样本外年份
3. 全样本缩尾存在预处理污染
4. PPT写死旧指标，无法反映新结果

修复动作

1. 因子改回
Reversal/Liquidity/MoneyFlow/Value
2. 质检仅使用2020-2023训练集
3. 缩尾改为交易日截面 3σ
4. 回测修正成本、末日结算与基准起点

最终口径

训练集：2020-2023
样本外：2024-01-02 ~ 2025-12-31
股票池：沪深300成分股
交易：每日Top5等权调仓

本页用于说明对AI初稿的人工审查与修补，后续所有图表均来自修复后重跑结果。

数据与样本隔离设计

本地Parquet数据：日频K线、daily_basic、5分钟线、财务指标、北向资金、沪深300指数。

274,669

训练样本行数

144,566

回测样本行数

970

训练IC截面

485

样本外交易日

299

股票数量

时间切分

训练集：2020-01-02 至 2023-12-29，用于因子质检、单因子OLS和LGBM训练。
回测集：2024-01-02 至 2025-12-31，仅用于样本外打分、交易和绩效评价。

数据限制

配套数据没有个股级 moneyflow_stock 的 buy_amount/sell_amount 字段，仅有市场级 moneyflow_hsgt。因此MoneyFlow采用个股成交额方向代理；去极值按交易日截面3 σ 执行。

四个中频短线因子定义

只使用作业要求的4个因子，不再引入Momentum、Volatility、Turnover、VolumeChange。

因子	定义	含义
Reversal	-当日个股收益率	短线反转
Liquidity	当日收益率 / 日成交额	交易摩擦/流动性
MoneyFlow	5日滚动签名成交额净流入 / 流通市值	个股资金流入流出代理
Value	1 / PE_TTM	低估值正向化

MoneyFlow代理口径

签名成交额 = amount / 10 × sign(ret)，其中amount为千元、circ_mv为万元；先按股票滚动5日求和，再除以流通市值。


目标标签

标签为个股次日超额收益 next_excess_ret，用于IC、OLS和LGBM训练；回测收益按持仓股票下一交易日ret结算。

训练集因子质检：IC/IR

IC为当期因子与次日超额收益的日度截面Spearman相关；只在2020-2023训练集上计算。

因子	IC均值	IR值	t统计量	有效判定	样本数
Reversal	0.0252	0.1446	4.96	有效	970
Liquidity	0.0224	0.1997	6.09	有效	970
MoneyFlow	-0.0228	-0.1419	-5.21	有效	970
Value	0.0117	0.0480	1.47	边缘	970



有效因子

Reversal、Liquidity、MoneyFlow达到 $|IC| \geq 0.02$ ；Value为边缘因子，按课程规则保留进入后续模型。

方向解释

MoneyFlow的IC为负，说明在当前代理口径下，极端资金拥挤后的短期回撤更明显。


稳定性

Liquidity IR最高，为0.1997；Reversal与MoneyFlow也超过 $|0.1|$ 稳定阈值。

IC时间序列

观察因子在训练期不同市场阶段下的预测能力波动。

因子IC时间序列



共线性与单因子OLS

VIF用于排查因子冗余，OLS用于线性有效性量化；不因OLS失效而剔除非线性候选因子。

因子	VIF	R ²	判定
Reversal	1.1016	0.0922	正常
Liquidity	1.0061	0.0060	正常
MoneyFlow	1.1039	0.0941	正常
Value	1.0063	0.0063	正常

因子	β均值	p值均值	判定
Reversal	-0.000408	0.2057	待定(非线性)
Liquidity	0.000859	0.3339	待定(非线性)
MoneyFlow	0.000028	0.2225	待定(非线性)
Value	-0.000250	0.1588	待定(非线性)

VIF结论

四个因子VIF均接近1，远低于VIF>5的高共线阈值，可全部纳入LGBM。

OLS结论

四个因子p值均高于0.05，线性维度待定；按作业规则全部进入LGBM做非线性二次筛选。


LGBM非线性赋权

训练样本只来自2020-2023；特征为4个标准化因子，标签为次日超额收益。

折数	训练MSE	验证MSE
1	0.000864	0.000822
2	0.000835	0.000781
3	0.000822	0.000698
4	0.000782	0.000576
5	0.000743	0.000410

交叉验证

5折扩展窗口时间序列CV，最佳为Fold 5，验证MSE=0.000410。



重要性

Liquidity权重最高，其次为Value、Reversal、MoneyFlow；模型自动学习非线性组合。

日频截面选股与交易规则

综合得分为LGBM预测的个股次日超额收益，得分越高越优先买入。

打分

每日收盘后对沪深300股票池逐只预测次日超额收益，并按预测值从高到低排序。

选股

每日选择Top5股票，等权持仓，每只股票目标权重20%。

成本

初始建仓扣单边0.1%；后续调仓按卖出+买入实际换手部分扣成本。

时间对齐


T日收盘产生信号并调仓；T+1日用持仓股票日收益结算。最后一个回测日只结算持仓，不再新开无效仓位。

交易日志

输出每日调仓记录，共484条；包含持仓、买入、卖出、换手率和成本。

样本外回测核心指标

回测区间：2024-01-02 至 2025-12-31，初始资金100万元，单边交易成本0.1%。




回测核心绩效指标

指标	数值
回测区间	2024-01-02 ~ 2025-12-31
回测天数	485
累计收益率	15.37%
年化收益率	7.71%
夏普比率	0.3215
最大回撤	-40.59%
日胜率	44.95%
超额收益(累计)	-21.35%
超额收益(年化)	-9.93%
信息比率	-0.0656
Calmar比率	0.19
初始资金	1,000,000
最终净值	1,153,739

策略净值 vs 沪深300


策略取得正收益 沪深300取得正收益 策略取得负收益 沪深300取得负收益

作业4B：策略净值 vs 沪深300



回撤分析

最大回撤为-40.59% 主要波动阶段的风险暴露与回撤



研究结论

四因子中频短线流程取得正收益，但相对基准承压，风险暴露仍需进一步约束。

因子层

Reversal、Liquidity、MoneyFlow在训练集IC层面有效；Value为边缘因子但对LGBM非线性组合有贡献。

模型层

LGBM可处理OLS难以刻画的非线性关系；特征重要性显示流动性和估值是主要分裂收益来源。

交易层

每日Top5换仓带来较高信号响应速度，也带来较高交易成本和回撤风险。

下一步优化方向：加入仓位上限、行业中性、止损/止盈规则，并对MoneyFlow代理口径做稳健性检验。

AI辅助编程审查反思

AI能快速生成流程，但量化作业必须进行数据口径、时序逻辑和结果真实性审查。

AI初稿风险

AI倾向为了提升结果加入额外因子；也容易将全样本统计结果写入PPT，造成样本外信息污染。

人工修复价值

人工审查将因子口径、训练/回测隔离、交易成本、最后交易日处理逐项校正，使结果可解释、可复现。

保留限制

MoneyFlow受限于本地数据字段，只能使用个股级代理；这会影响经济解释强度。

提交材料

PPT、AI代码审查记录、AI交互记录、回测图表/指标表格均已按修复后结果更新。

提交文件清单

命名遵循：学号 + 姓名 + 作业4B。

类别	文件/目录	说明
PPT	202331060205_丁致宇_作业4B.pptx / .pdf	演示文稿
代码	homework4b/	全流程源码
数据	data/homework4b/train_data.csv、test_data.csv、full_data.csv、数据说明.md	清洗后训练/回测/全量数据
图表	outputs/homework4b/*.png	净值、回撤、IC、重要性
指标表	summary.json、IC/VIF/OLS/feature_importance/backtest_result	可复核数据结果
AI记录	AI代码审核记录.md、AI交互记录.md、AI交互记录.docx、AI代码审查与修复表.docx	AI辅助与人工修复过程

核心结论：严格四因子口径和按日截面缩尾后，样本外累计收益15.37%，相对沪深300累计超额-21.35%；结果低于AI初稿，但更符合题目要求和回测真实性。